

Podobnie jak w poprzednim przykładzie, odpowiednie warunki szybkiej akceptacji i szybkiej eliminacji mogą znacznie przyspieszyć działanie algorytmu (patrz p. 3.2.3).

Zwróćmy uwagę na następujące dwa lematy:

LEMAT 3.5. Jeżeli punkt losowy (U, V) ma rozkład równomierny na zbiorze $\{(u, v): 0 \leq u \leq f(u+v)\}$, to zmienna losowa $U + V$ ma rozkład o gęstości proporcjonalnej do f . \square

LEMAT 3.6. Jeżeli punkt losowy (U, V) ma rozkład równomierny na zbiorze $\{(u, v): 0 \leq u \leq (f(v/\sqrt{u}))^{2/3}\}$, to zmienna losowa V/\sqrt{U} ma rozkład o gęstości proporcjonalnej do f . \square

Te dwa lematy sugerują inne warianty oraz uogólnienia metody ROU.

3.1.5. Rozkłady dyskretne

Metoda odwracania dystrybucji

Metoda odwracania dystrybucji, o której mówiliśmy w p. 3.1.1, w przypadku rozkładów dyskretnych prowadzi do wzoru (3.3). Dla rozkładu prawdopodobieństwa $P\{X = k\} = p_k$, $k = 0, 1, 2, \dots$ otrzymujemy prosty algorytm

ALGORYTM 3.19

$X = 0$, $S = p_0$

Generuj U o rozkładzie równomiernym $U(0, 1)$

While $U > S$

do $X = X + 1$, $S = S + p_X$

Return X

Łatwe uogólnienie tego algorytmu na przypadek rozkładu

$$P\{X = x_k\} = p_k, \quad k = 0, 1, 2, \dots \quad (3.20)$$

pozostawiamy Czytelnikowi.

Liczba N kroków w pętli *while* ma rozkład $P\{N = k\} = p_k$, może się więc okazać, że wartość oczekiwana tej zmiennej losowej jest bardzo duża lub nawet równa $+\infty$. Wynika stąd, że ten prosty algorytm może pracować bardzo wolno. Tak jest np. w niektórych dyskretnych wersjach rozkładu Pareto. Pewne przyspieszenie algorytmu można uzyskać przez taką permutację ciągu liczb p_0, p_1, p_2, \dots , żeby w nowym ciągu $p_{(0)}, p_{(1)}, p_{(2)}, \dots$ były spełnione nierówności

$$p_{(0)} \geq p_{(1)} \geq p_{(2)} \geq \dots$$

Jeżeli dokonamy takiej samej permutacji liczb x_0, x_1, x_2, \dots , to zmienna losowa Y o rozkładzie $P\{Y = x_{(k)}\} = p_{(k)}$, $k = 0, 1, 2, \dots$, będzie miała taki sam rozkład jak zmienna losowa X , ale średnia liczba kroków w pętli *while* będzie mniejsza.

Metoda równomiernego rozbicia przedziału (0,1)

Metodę odwracania dystrybucyj można interpretować w następujący sposób. Rozbijamy przedział (0,1) na rozłączne podprzedziały o długościach równych p_0, p_1, p_2, \dots . Każdemu podprzedziałowi przyporządkowujemy odpowiednią wartość zmiennej losowej: podprzedziałowi o długości p_i wartość x_i . Generujemy liczbę losową U o rozkładzie równomiernym $U(0,1)$ i za wynik generowania zmiennej losowej X przyjmujemy tę wartość x_i , która odpowiada podprzedziałowi, do którego wpadło to U .

Metoda równomiernego rozbicia przedziału (0,1) polega na podzieleniu przedziału (0,1) na jednakowo długie podprzedziały, sprawdzeniu, do którego z nich wpadło U , a następnie na identyfikowaniu wartości generowanej zmiennej losowej X już tylko w tym małym podprzedziale. Oto szczegóły.

Rozważamy zmienną losową X przyjmującą skończoną liczbę różnych wartości

$$P\{X = k\} = p_k, \quad k = 0, 1, \dots, K \quad (3.21)$$

Dzielimy przedział (0,1) na $K+1$ podprzedziałów $(\frac{i-1}{K+1}, \frac{i}{K+1})$ o jednakowej długości i umawiamy się, że odcinek $(0, \frac{1}{K+1})$ ma numer 1. Zatem zmienna U wpada do podprzedziału o numerze $[(K+1)U + 1]$.

Dla danego rozkładu (3.21) tworzymy ciąg $q_i = \sum_{j=0}^i p_j$, $i = 0, 1, \dots, K$, i przyjmujemy $q_{-1} = 0$. Następnie tworzymy pomocniczy ciąg liczb

$$g_i = \max \left\{ j: q_j < \frac{i}{K+1} \right\}, \quad i = 1, 2, \dots, K+1 \quad (3.22)$$

umawiając się przy tym, że maksimum na zbiorze pustym jest równe zeru. Po tych przygotowaniach algorytm generowania liczb losowych o rozkładzie (3.21) przyjmuje następującą postać:

ALGORYTM 3.20

Generuj U o rozkładzie równomiernym $U(0,1)$

$X = [(K+1)U + 1]$

$X = g_X + 1$

While $q_{X-1} > U$ do $X = X - 1$

Return X

Najważniejsza własność tego algorytmu jest opisana w następującym twierdzeniu:

TWIERDZENIE 3.5. *Oczekiwana liczba porównań $\{q_{X-1} > U\}$ jest nie większa od 2.*

D o w ó d. Jeżeli w pierwszym kroku algorytmu został wybrany podprzedział o numerze i , to liczba porównań $\{q_{X-1} > U\}$ nie będzie większa od liczby różnych wartości q_j w tym podprzedziale, plus jeden. Każdy z $K+1$ podprzedziałów jest wybierany z jednakowym prawdopodobieństwem, więc

oczekiwana liczba porównań \leq

$$\leq 1 + \frac{1}{K+1} \sum_{i=0}^K (\text{liczba różnych } q_j \text{ w } i\text{-tym przedziale}) = 2$$

□

Pomysł metody równomiernego rozbicia przedziału $(0, 1)$ pochodzi z pracy Chena i Asau (1974), a opis tej metody podaliśmy według monografii Devroya (1986). W literaturze anglojęzycznej ta metoda nosi nazwę *method of guide tables*.

Mieszanie rozkładów dwupunktowych

Mówimy, że rozkład o gęstości $f(x)$ jest *mieszaniną* k rozkładów o gęstościach $f_i(x)$, $i = 0, 1, \dots, k-1$, jeżeli

$$f(x) = \sum_{i=0}^{k-1} \lambda_i f_i(x)$$

gdzie

$$\sum_{i=0}^{k-1} \lambda_i = 1, \quad \lambda_i > 0, \quad i = 0, 1, \dots, k-1$$

Weźmy pod uwagę zmienną losową X o rozkładzie dyskretnym

$$P\{X = x_i\} = p_i, \quad i = 0, 1, \dots, k-1 \quad (3.23)$$

Mówimy, że rozkład (3.23) jest *równomierną mieszaniną rozkładów dwupunktowych*, jeżeli istnieją ciąg par liczb (u_j, v_j) , $j = 0, 1, \dots, k-1$, oraz ciąg liczb $q_j \in (0, 1)$, $j = 0, 1, \dots, k-1$, takie że

$$p_i = \frac{1}{k} \sum_{j=0}^{k-1} (q_j 1_{\{u_j\}}(x_i) + (1 - q_j) 1_{\{v_j\}}(x_i)), \quad i = 0, 1, \dots, k-1 \quad (3.24)$$

Generowanie liczb losowych X o rozkładzie dyskretnym (3.23), który jest równomierną mieszaniną rozkładów dwupunktowych, jest bardzo łatwe i szybkie: wystarczy wygenerować indeks J według rozkładu równomiernego na zbiorze $\{0, 1, \dots, k-1\}$, a następnie wygenerować X według J -tego rozkładu dwupunktowego

$$P\{X = u_j\} = q_j, \quad P\{X = v_j\} = 1 - q_j$$

TWIERDZENIE 3.6. Każdy rozkład dyskretny postaci (3.23) można przedstawić w postaci równomiernej mieszaniny (3.24) rozkładów dwupunktowych.

D o w ó d (indukcyjny). Dla $k=1$ mamy oczywiście $u_0=x_0$ i $q_0=p_0(=1)$. Przypuśćmy, że teza jest prawdziwa dla rozkładów $(k-1)$ -punktowych i rozpatrzmy k -punktowy rozkład (3.23).

Niech i_0 będzie takim wskaźnikiem, że

$$p_{i_0} = \min_{0 \leq i < k} p_i$$

Podstawmy $u_0 = x_{i_0}$ oraz $q_0 = kp_{i_0}$ (mamy oczywiście $p_{i_0} \leq 1/k$, więc $kp_{i_0} \leq 1$). Niech j_0 będzie takim wskaźnikiem, że

$$p_{j_0} = \max_{0 \leq i < k} p_i$$

Mamy oczywiście $p_{j_0} \geq 1/k$, więc $(1 - q_0)/k \leq p_{j_0}$. Podstawmy $v_0 = x_{j_0}$. Wielkości (u_0, v_0) oraz q_0 potraktujmy jako pierwszy składnik sumy (3.24). Liczby

$$p'_i = p_i - \frac{1}{k} (q_0 1_{\{u_0\}}(x_i) + (1 - q_0) 1_{\{v_0\}}(x_i)), \quad 0 \leq i < k$$

są nieujemne i sumują się do $1 - \frac{1}{k}$, przy czym $p'_{i_0} = 0$. Teraz

$$\begin{pmatrix} x_0 & x_1 & \dots & x_{i_0-1} & x_{i_0+1} & \dots & x_{k-1} \\ \tilde{p}_0 & \tilde{p}_1 & \dots & \tilde{p}_{i_0-1} & \tilde{p}_{i_0+1} & \dots & \tilde{p}_{k-1} \end{pmatrix}$$

gdzie $\tilde{p}_i = kp'_i/(k-1)$, jest $(k-1)$ -punktowym rozkładem prawdopodobieństwa, który na mocy założenia indukcyjnego może być przedstawiony w postaci (3.24), co kończy dowód. \square

Algorytm korzysta z trzech następujących bloków liczb: $(q_0, q_1, \dots, q_{k-1})$, $(u_0, u_1, \dots, u_{k-1})$ oraz $(v_0, v_1, \dots, v_{k-1})$ i przebiega według następującego schematu:

ALGORYTM 3.21

Generuj U_1 o rozkładzie równomiernym $U(0,1)$

Generuj U_2 o rozkładzie równomiernym $U(0,1)$

$I = [kU_1]$

If $U_2 \leq q_I$ then $X = u_I$ else $X = v_I$

Return X

Ten algorytm dwukrotnie odwołuje się do generowania liczb losowych o rozkładzie równomiernym $U(0,1)$; korzystając z następującego lematu, można te dwa odwołania zredukować do jednego.

LEMAT 3.7. Jeżeli zmienna losowa U ma rozkład równomierny $U(0,1)$, to zmienna losowa $[kU]$ ma rozkład równomierny na zbiorze $\{0, 1, \dots, k-1\}$, zmienna losowa $\{kU\}$ ma rozkład równomierny $U(0,1)$ i te zmienne losowe są niezależne.

D o w ó d pozostawiamy Czytelnikowi. \square